DogHybridSystem-Icon



Integrazione di ragionamento deduttivo e apprendimento supervisionato

Gruppo di lavoro

- Anna Maffione, 777004, a.maffione9@studenti.uniba.it

URL: https://github.com/annamaffione03/DogHybridSystem-ICon

Anno accademico: 2025-2026 (primo anno fuori corso)

INDICE

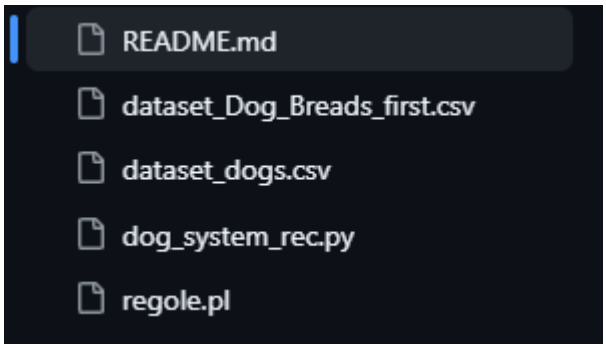
1. Introduzione
2. Sommario
3. Elenco argomenti di interesse
4. Sezione argomento 1
    a. Sommario
    b. Strumenti utilizzati
    c. Decisioni di progetto
    d. Valutazione
5. Sezione argomenti 2
    a. Sommario
    b. Strumenti utilizzati
    c. Decisioni di progetto
    d. Valutazione
6. Sezione argomenti 3
    a. Sommario
    b. Strumenti utilizzati
    c. Decisioni di progetto
    d. Valutazione
7. Conclusioni
8. Riferimenti bibliografici

1. INTRODUZIONE

Il dominio applicativo riguarda la selezione, analisi decisionale e profilazione delle razze canine al fine di individuare profili e compatibilità con vita e contesti urbani presi dall'interno di un catalogo di caratteristiche fisiche e comportamentali dei cani.

Questo catalogo è caratterizzato da vincoli e caratteristiche rigide (la taglia del cane e il livello di energia) e relazioni di ereditarietà (attitudine al gioco, alla protezione).

Il problema viene affrontato formalizzando il dominio mediante un sistema a base di conoscenza. Il progetto è stato realizzato in python in quanto è un linguaggio intuitivo e con varie librerie a disposizione.



2. SOMMARIO

Il presente progetto affronta lo sviluppo di un KBS ibrido finalizzato alla valutazione automatica dell'idoneità delle razze canine alla vita di appartamento. Per il mio progetto la scelta delle colonne è ricaduta su:

- DogBreed nome della razza del cane (labrador, pastore tedesco, ecc…);
- FciGroup appartenenza del cane a uno dei gruppi FCI (cani da pastore, terrier, ecc…);
- comp_1 , comp_2, comp_3 (socievole, giocherellone, protettivo, attivo, calmo, indipendente e diffidente);
- DogSize taglia del cane che può essere piccolo, medio, grande;
- DogEnergy livello di energia del cane che può essere basso, medio, alto e intenso;
- Target è la nostra variabile booleana per l'idoneità all'appartamento del cane.

Il sistema svolge 4 passi generali:

1. Analizza un dataset contenente caratteristiche delle razze canine esportato da kaggle, esso non avendo tutte le colonne e informazioni è stato modificato per adattarlo alle nostre necessità;

```
import pandas as pd
df = pd.read_csv("dataset_Dog_Breads_first.csv")
print("Colonne originali:", df.columns)

# Rinominiamo le colonne principali adattandole alle nostre 8 colonne
# Esempio: 'Nome' -> DogBreed, 'Taglia' -> DogSize, ecc.

 df = df.rename(columns={
     'NomeColonnaOriginale1': 'DogBreed',
     'NomeColonnaOriginale2': 'FciGroup',
     'Taglia': 'DogSize',
     'Fabbisogno di esercizio': 'DogEnergy'
 })

#Creiamo le colonne mancanti (es. i comportamenti comp_1, comp_2, comp_3 e il target)
df['comp_1'] = 'calmo'      # Valore di default o mappato
df['comp_2'] = 'socievole'  # Valore di default o mappato
df['comp_3'] = 'giocherellone'
df['target'] = 'yes'        # Sarà poi sovrascritto da Prolog

#Salviamo il nuovo file pulito pronto per Prolog
df.to_csv("dataset_dogs.csv", index=False)
print("File pulito salvato con successo come 'dataset_dogs.csv'!")
```

```
Colonne originali: Index(['Name', 'Origin', 'Type', 'Unique Feature', 'Friendly Rating (1-10)',
       'Life Span', 'Size', 'Grooming Needs',
       'Exercise Requirements (hrs/day)', 'Good with Children',
       'Intelligence Rating (1-10)', 'Shedding Level', 'Health Issues Risk',
       'Average Weight (kg)', 'Training Difficulty (1-10)'],
      dtype='object')
```

2. Interroga la base di conoscenza tramite la libreria PySwip, applicando regole multi-condizionali e criteri di esclusione;
3. Classifica ogni istanza determinando l'idoneità della razza canina alla vita di appartamento tramite target;
4. Esporta il risultato in un dataset finale.

3. *ELENCO ARGOMENTI DI INTERESSE*

Argomento	Sezione Programma	Tecniche e Modelli Adottati	Ruolo KBS
Rappresentazione e Deduzione	Parte II (Logica)	Clausole di Horn, Tassonomie, Ereditarietà comportamentale, NAF (CWA), Risoluzione SLD	Filtro vincolare deterministico e classificazione logica iniziale della compatibilità
Analisi dei Dati e Preprocessing	Parte III (Gestione e Analisi)	Pulizia del dataset, One-Hot Encoding, binarizzazione del target logico	Normalizzazione e preparazione della base dati tabulare per la pipeline ibrida
Apprendimento Supervisionato	Parte IV (Machine Learning)	Random Forest Classifier, addestramento su feature etichettate	Predizione non lineare e stima probabilistica della idoneità abitativa complessiva

Rappresentazione e deduzione riguarda la sezione due del programma (logica) e tra le tecniche abbiamo: Tassonomie, Clausole di Horn, Ereditarietà, NAF (CWA), Risoluzione SLD.

Analisi dei dati e prepocessing riguarda la sezione tre del programma (gestione e analisi) e tra le tecniche abbiamo: Pulizia del dataset, One-Hot Encoding, binarizzazione del target logico.

Apprendimento supervisionato riguarda la sezione 4 del programma (machine learning) con tecniche Random Forest Classifier, K-Fold Cross-

Validation. Essa è una branca dell'apprendimento automatico in cui l'agente viene addestrato su un insieme di dati con etichette. Si divide in Classificazione: le etichette rappresentano un dominio di valori discreto (quindi un insieme finito di valori) che la feature di output può assumere e Regressione: l'etichetta può essere un qualsiasi valore numerico. L'obiettivo principale è far sì che l'algoritmo impari una relazione tra gli input e gli output in modo che, una volta addestrato, possa fare previsioni accurate su nuovi dati mai visti prima.

4. SEZIONE ARGOMENTO 1 RAPPRESENTAZIONE E DEDUZIONE

Questa sezione descrive la formalizzazione ontologica e logica del dominio tramite "regole.pl"

- Sono state definite categorie astratte per gestire la complessità ontologica, suddividendo la taglia (compact_size, heavy_size) e l'energia (manageable_energy, excessive_energy)

```
% Categorie di taglia estese
compact_size(piccolo).
compact_size(medio).
heavy_size(grande).

manageable_energy(basso).
manageable_energy(medio).
excessive_energy(intenso).
excessive_energy(alto).
```

- Le proprietà comportamentali sono ereditate attraverso regole relazionali (has_behavior(Breed, Trait)), che aggregano tratti comportamentali multipli;

```
% Regola relazionale per l'ereditarietà delle proprietà comportamentali
has_behavior(Breed, Trait) :- comp_1(Breed, Trait).
has_behavior(Breed, Trait) :- comp_2(Breed, Trait).
has_behavior(Breed, Trait) :- comp_3(Breed, Trait).
```

- Vengono impiegate clausole condizionali per definire profili gestibili o criteri di ammissione mirati (es. cani di media taglia socievoli e a bassa energia, oppure grandi taglie ammesse solo in regime di calma assoluta e assenza di attivazione elevata);

```
% Regola 2: I cani di media taglia con comportamento calmo ed energia non eccessiva
target(Breed, yes) :-
    dog_size(Breed, medio),
    has_behavior(Breed, calmo),
    dog_energy(Breed, Energy),
    \+ excessive_energy(Energy).
```

- CWA e NAF Sfruttando l'operatore di negazione per fallimento (\+), il sistema implementa regole di esclusione rigide (scartare automaticamente cani con energia eccessiva o diffidenti ad alto livello di energia) e un fallback finale che garantisce la completezza della base di conoscenza (target(Breed, no) :- \+ target(Breed, yes)).

```
target(Breed, no) :-
    has_behavior(Breed, diffidente),
    dog_energy(Breed, alto).

```

```
% Regola 4: Cani di grande taglia ammessi SOLO con profili di calma assoluta
target(Breed, yes) :-
    dog_size(Breed, grande),
    has_behavior(Breed, calmo),
    dog_energy(Breed, basso),
    \+ has_behavior(Breed, attivo).
```

5. *SEZIONE ARGOMENTO 2*
ANALISI DEI DATI E PREPROCESSING

La gestione e l'analisi preventiva del dataset hanno richiesto una serie di passaggi fondamentali per rendere i dati compatibili sia con il motore logico che con gli algoritmi di apprendimento come anticipato nel sommario, le operazioni svolte sono state:

- Effettuata pulizia dataset con rimozione di valori nulli, normalizzazione delle stringhe e strutturazione delle colonne (es. DogBreed, DogSize, DogEnergy) nel file dataset_dogs.csv.
- Interrogazione e Binarizzazione del Target Logico dove lo script Python (dog_system_rec.py) interroga iterativamente la base di conoscenza per ogni razza canina. Il risultato testuale (yes/no) viene binarizzato in un target numerico booleano (y_ml = (df['prolog_target'] == 'yes').astype(int)), fungendo da etichetta di supervisione per il modulo ML.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1	DogBreed	Origin	FciGroup	Unique Fe	Friendly R	Life Span	DogSize	Grooming	Exercise R	Good with	Intelligenc	Shedding	Health Iss	Average W	Training D	comp_1	comp_2	comp_3	DogEnergy	target
2	Affenpins	Germany	Toy	Monkey-li	7	14	Small	High	1.5	Yes	8	Moderate	Low	4	6	calmo	socievole	giocherell	medio	yes
3	Afghan Hc	Afghanist	Hound	Long silky	5	13	Large	Very High	2.0	No	4	High	Moderate	25	8	calmo	socievole	giocherell	medio	yes
4	Airedale T	England	Terrier	Largest of	8	12	Medium	High	2.0	Yes	7	Moderate	Low	21	6	calmo	socievole	giocherell	medio	yes
5	Akita	Japan	Working	Strong loy	6	11	Large	Moderate	2.0	With Train	7	High	High	45	9	calmo	socievole	giocherell	medio	yes
6	Alaskan M	Alaska US	Working	Strong pul	7	11	Large	High	3.0	Yes	6	Very High	Moderate	36	8	calmo	socievole	giocherell	medio	yes
7	American	USA	Working	Muscular	8	11	Large	Low	2.0	Yes	6	Moderate	Moderate	42	7	calmo	socievole	giocherell	medio	yes
8	American	USA	Non-Sport	Pure white	9	14	Small-Me	High	2.0	Yes	9	High	Low	12	5	calmo	socievole	giocherell	medio	yes
9	American	USA	Hound	Musical v	8	12	Medium	Low	2.5	Yes	6	Moderate	Low	31	6	calmo	socievole	giocherell	medio	yes
10	Australiar	Australia	Herding	Unique bl	7	14	Medium	Moderate	2.5	Yes	9	Moderate	Low	15	7	calmo	socievole	giocherell	medio	yes
11	Australiar	USA	Herding	Merle colc	8	14	Medium	High	2.5	Yes	9	High	Moderate	25	7	calmo	socievole	giocherell	medio	yes
12	Australiar	Australia	Terrier	Small but	7	13	Small	Moderate	1.5	Yes	7	Low	Low	6.5	6	calmo	socievole	giocherell	medio	yes
13	Basenji	Central Afi	Hound	Doesn't ba	6	13	Small-Me	Low	2.0	No	6	Low	Low	10	9	calmo	socievole	giocherell	medio	yes
14	Basset Ho	France	Hound	Short legs	8	11	Medium	Low	1.0	Yes	5	Moderate	High	24	7	calmo	socievole	giocherell	medio	yes
15	Beagle	England	Hound	Excellent s	9	13	Small-Me	Low	2.0	Yes	7	Moderate	Moderate	10	7	calmo	socievole	giocherell	medio	yes
16	Bearded C	Scotland	Herding	Long shag	8	13	Medium	Very High	2.0	Yes	8	High	Low	22	6	calmo	socievole	giocherell	medio	yes
17	Bernese M	Switzerlar	Working	Tri-colore	9	8	Large	High	1.5	Yes	7	High	High	43	5	calmo	socievole	giocherell	medio	yes
18	Bichon Fri	Mediterra	Non-Sport	Cotton-lik	9	13	Small	Very High	1.0	Yes	8	Low	Low	4	5	calmo	socievole	giocherell	medio	yes
19	Black Rus	Russia	Working	Black prot	7	11	Large	High	2.0	Yes	8	Moderate	Moderate	50	8	calmo	socievole	giocherell	medio	yes
20	Bloodhou	Belgium	Hound	Superior t	7	11	Large	Moderate	2.0	Yes	6	Moderate	High	43	8	calmo	socievole	giocherell	medio	yes

- Le feature categoriche di input (come DogSize e DogEnergy) sono state trasformate in matrici numeriche binarie tramite pd.get_dummies(..., drop_first=True), evitando problemi di multicollinearità e rendendo i dati elaborabili dal classificatore statistico.

6. SEZIONE ARGOMENTO 3 APPRENDIMENTO SUPERVISIONATO

L'apprendimento supervisionato è stato introdotto per addestrare un agente basato su dati etichettati (derivati dal filtraggio logico precedente):

- È stato utilizzato un Random Forest Classifier (n_estimators=100, max_depth=5), un ensemble di alberi di decisione ideale per catturare non-linearità e relazioni complesse tra taglia, energia e compatibilità urbana;

```
for train_index, test_index in kf.split(X_encoded):
    X_train, X_test = X_encoded.iloc[train_index], X_encoded.iloc[test_index]
    y_train, y_test = y_ml.iloc[train_index], y_ml.iloc[test_index]

    rf_model = RandomForestClassifier(n_estimators=100, max_depth=5, random_state=42)
    rf_model.fit(X_train, y_train)
    y_pred = rf_model.predict(X_test)
```

- Validazione Rigorosa (K-Fold Cross-Validation) Per evitare l'overfitting e garantire la robustezza statistica del modello, è stata applicata una K-Fold Cross-Validation con $K = 5$ (shuffle=True);

```
print("[3/4] Valutazione delle performance con K-Fold Cross-Validation (K=5)...")
kf = KFold(n_splits=5, shuffle=True, random_state=42)
```

- Le performance sono state misurate calcolando l'Accuratezza Media e l'F1-Score Medio su ciascun fold di test, monitorando la deviazione standard per attestare la stabilità predittiva del sistema.
- Al termine della validazione, il modello finale viene addestrato sull'intero set di dati codificati per stimare la probabilità continua (predict_proba), combinata infine con il verdetto simbolico per generare il file di output definitivo.

7. CONCLUSIONI

Il progetto ha dimostrato con successo l'efficacia e la robustezza di un approccio ibrido a due paradigmi per la profilazione e la valutazione della compatibilità delle razze canine in contesto urbano. L'integrazione tra il modulo simbolico deduttivo e l'apprendimento supervisionato ha permesso di superare i limiti intrinseci dei singoli sistemi.

L'integrazione tra la base di conoscenza in SWI-Prolog (che gestisce tassonomie, clausole di Horn e la chiusura logica tramite NAF) e la pipeline di elaborazione in Python (tramite pandas, PySwip e scikit-learn) ha permesso di superare i limiti dei sistemi puramente basati su regole o dei database statici.

Nonostante gli obiettivi prefissati siano stati raggiunti, il sistema presenta margini di estensione e miglioramento, attualmente il sistema valuta la razza in astratto rispetto al contesto urbano generale.

Delle possibili estensioni potrebbero essere:

- Consisterebbe nell'integrare un profilo utente inserendo ad esempio presenza di bambini o altri animali, varie tipologie di abitazione consentendo raccomandazioni personalizzate "utente-cane" anziché basate solo sulla razza;

- Un'altra potrebbe essere quella ingrandire la base di conoscenza e il dataset che possono essere arricchiti con un numero maggiore di tratti comportamentali complessi come livello di tolleranza alla solitudine, facilità di addestramento, attitudine specifica verso estranei o altri animali).